

FarmIA

1. Investigación y Selección de Arquitectura

FarmIA requiere de una arquitectura capaz de manejar grandes volúmenes de datos, soportar el crecimiento, la integración de nuevas fuentes y el análisis en tiempo real. La empresa prevé triplicar su volumen de datos en los próximos dos años, y actualmente, cuenta con una plataforma de ventas en línea y un sistema local de inventarios; además, planea incorporar sensores en campos agrícolas, datos de clientes en tiempo real, aplicaciones móviles y canales de venta de terceros. Por tanto, la solución propuesta debe ser escalable, flexible, eficiente y desplegable en el entorno cloud de Azure.

A partir del material de clase, se analizaron cuatro (4) arquitecturas de datos, tomadas de las seis presentadas en clase (Data Warehouse, Data Lake, Data Mesh y Data Lakehouse). En primera instancia, se consideró el *Data Warehouse (DW)*, opción que presenta limitantes de escalabilidad y coste. Por ello, aunque sería adecuado para cuadros de mando y análisis clásicos, no funcionaría de la mejor forma para integrar sensores, eventos en tiempo real y nuevas fuentes heterogéneas, porque DW soporta principalmente datos estructurados, presenta limitaciones de crecimiento y desde el punto de vista económico representa un alto costo.

Luego, se analizó el *Data Lake*, arquitectura que aporta alta flexibilidad, almacenamiento masivo y posibilidad de trabajar con distintos tipos de datos, ya que permite almacenar la información en su forma original. Sin embargo, sus principales limitaciones son la falta de transaccionalidad, la complejidad del gobierno de datos, la necesidad de conocimientos avanzados y la lentitud en la consulta y el consumo de datos. En consecuencia, aunque un Data Lake sería flexible para FarmIA, no sería suficiente por sí solo para resolver las necesidades.

También se valoró el enfoque *Data Mesh*. No obstante, este modelo se centra más en la organización y distribución de responsabilidades por dominio de negocio que en una solución tecnológica concreta. De acuerdo con los apuntes de clase, esta arquitectura se identifica como más organizativa que técnica. Por esta razón, no representa la mejor respuesta principal para el caso actual.

La arquitectura seleccionada es *Data Lakehouse en Azure con ingesta híbrida batch más streaming, organizada mediante Medallion Architecture* en capas *Bronze, Silver y Gold*. Esta elección resulta adecuada porque combina la flexibilidad del Data Lake con capacidades analíticas más estructuradas, integrando en un único repositorio tanto datos históricos y estructurados como datos generados en tiempo real. Además, el Data Lakehouse se define como una solución que integra lago y almacén de datos en un solo repositorio mediante una capa transaccional, y la Medallion Architecture permite mejorar de forma progresiva la estructura y la calidad del dato.

En el caso concreto de FarmIA, esta arquitectura permite gestionar de forma conjunta la plataforma de ventas en línea, el sistema local de inventarios, los sensores agrícolas, los datos de clientes en tiempo real, la aplicación móvil y los canales de venta de terceros. Asimismo, facilita el tratamiento simultáneo de procesos batch y streaming, permite escalar ante el crecimiento previsto del

volumen de datos y deja la información preparada para su consumo posterior en herramientas analíticas y de negocio. En consecuencia, la arquitectura Data Lakehouse en Azure se considera la alternativa más adecuada para responder a las necesidades actuales y futuras de la empresa.

2. Justificación

2.1. CAPA ORIGEN

Los orígenes de FarmlA combinan fuentes internas y externas, así como datos batch y streaming, lo que justifica una arquitectura que sea flexible y escalable.

La *plataforma de ventas en línea* constituye un origen interno híbrido, ya que genera datos streaming, como navegación, actividad del carrito y compras en tiempo real. También, genera datos batch, como cierres diarios, exportaciones, consolidaciones e históricos.

El *sistema local de inventarios* es un origen interno, batch y asociado a datos en reposo y normalmente integrado mediante un modelo Pull porque es una fuente estructurada cuyos datos ya se encuentran almacenados. Por su parte, los *sensores en campos agrícolas* constituyen un origen interno streaming, ya que generan datos en movimiento, como temperatura, humedad y más variables que normalmente se asocian a mecanismos de integración push.

La *aplicación móvil*, en caso de pertenecer a FarmlA, también constituye un origen interno streaming. Los eventos generados por los usuarios dentro de la aplicación se consideran datos en movimiento y suelen integrarse por medio de mecanismos push.

Los *eventos de clientes en tiempo real*, como clics, compras o navegación, constituyen otra fuente interna streaming. Estos datos permiten identificar cambios rápidos en el comportamiento del cliente, picos de demanda y patrones de consumo recientes.

Por último, *los canales de venta de terceros* constituyen orígenes externos. Dependiendo del proveedor, su integración puede realizarse en modo streaming, si envían eventos o webhooks en tiempo real, o en modo batch, si entregan reportes, archivos o extracciones programadas.

En conjunto, los orígenes de FarmlA representan una mezcla de datos estructurados, semi-estructurados y en tiempo real. Por ello, la siguiente capa de la arquitectura debe ser capaz de capturar tanto datos batch como datos streaming desde fuentes heterogéneas.

2.2. CAPA INGESTA

La capa de ingesta extrae y captura la información desde sus orígenes hacia un almacenamiento centralizado. En el caso de FarmlA, esta capa es fundamental porque la empresa combina fuentes batch y streaming, internas y externas, y necesita integrar datos estructurados, semi-estructurados y en tiempo real dentro

de una misma plataforma. Además, debe garantizar la calidad de los datos, reducir el riesgo de pérdida o alteración y responder de forma escalable al crecimiento previsto.

La ingesta en FarmlA presenta varios desafíos. Uno de ellos es la gestión del *volumen y la velocidad*, ya que la plataforma deberá recibir tanto extracciones periódicas como eventos en tiempo real. Otro desafío es la *sincronización de datos*, especialmente en los escenarios streaming, donde resulta necesario asegurar que los eventos lleguen y se almacenen en el orden correcto. A esto se suma la *tolerancia a fallos*, ya que la pérdida de información afectaría la operación y los análisis posteriores. Por último, la *seguridad y privacidad* también son elementos críticos, dado que algunos datos pueden estar relacionados con clientes, transacciones y actividad digital.

En FarmlA se utilizan los modelos Pull como Push; donde el primero se aplica a los orígenes batch, es decir, datos ya almacenados que pueden extraerse de forma programada, como el sistema local de inventarios, archivos históricos e integraciones periódicas con terceros. Por su parte, el modelo Push se emplea en los flujos streaming, donde la fuente emite los datos a medida que se generan, como ocurre con sensores agrícolas, eventos de clientes en tiempo real, actividad de aplicaciones móviles y canales externos basados en webhooks.

A partir de ello, se plantean dos tipos de ingesta, la ingesta batch que estará orientada a datos en reposo, como inventario local, exportaciones, cierres diarios y archivos periódicos. La ingesta streaming se enfocará en datos en movimiento, como telemetría de sensores, navegación, clics y compras en tiempo real. Esta combinación permite integrar tanto información histórica como flujos recientes dentro de una misma arquitectura.

Desde el punto de vista tecnológico, la capa de ingesta de FarmlA se apoyará en herramientas diferenciadas según el tipo de flujo de datos. Para la ingesta batch orientada a inventario local, exportaciones, cierres diarios, archivos que son periódicos, se propone el uso de *Azure Data Factory*, ya que permite orquestar y mover datos desde sistemas o ficheros ya existentes hacia la plataforma de datos. Para la ingesta streaming, asociada a sensores agrícolas, eventos de clientes en tiempo real, actividades de la aplicación móvil y otros flujos de eventos, se plantea el uso de *Azure Event Hubs* y *Azure IoT Hub*, que permiten capturar información en tiempo real. De manera complementaria, podrían emplearse conectores del ecosistema *Kafka* cuando sea necesario integrar otras fuentes orientadas a eventos. Con esta combinación, FarmlA podrá capturar tanto datos en reposo como datos en movimiento de forma ordenada y coherente con una arquitectura Lakehouse en Azure.

2.3. CAPA DE ALMACENAMIENTO

La capa de almacenamiento busca centralizar y almacenar los datos de la empresa de forma escalable. En FarmlA, esta capa debe soportar tanto datos batch como streaming debido a la coexistencia de información histórica y flujos de datos generados en tiempo real. Por ello, el almacenamiento debe responder las necesidades de volumen y velocidad.

El almacenamiento principal se apoyará en *Azure Data Lake Storage (ADLS)*, ya que funciona como repositorio central del Lakehouse y permite conservar los datos de forma persistente, escalable y masiva en ficheros y blobs. Además, ADLS aporta una estructura lógica para organizar los datos por capas, zonas y dominios, favoreciendo la trazabilidad, el gobierno y la explotación analítica posterior. En esta arquitectura el almacenamiento batch será predominante.

Por otro lado, el caso de estudio requiere datos en tiempo real, como la telemetría de sensores, los eventos de clientes y la actividad de aplicaciones móviles; gracias a esto, puede existir almacenamiento streaming con carácter temporal, cuyo propósito sea acelerar el acceso o procesamiento inmediato del dato. Cabe destacar que este almacenamiento por sí solo no sería suficiente como repositorio principal, ya que, suele ser de corto plazo y los datos terminan persistidos de forma permanente en almacenamiento batch.

Por esta razón, la estrategia de almacenamiento propuesta consiste en persistir los datos dentro del Lakehouse y organizarlos mediante Medallion Architecture en capas Bronze, Silver y Gold. En la capa Bronze se conservarán los datos crudos tal como llegan desde la ingesta; en la capa Silver se almacenarán datos limpios, estandarizados e integrados; y en la capa Gold se mantendrán los datos de mejor calidad y preparados para su explotación analítica y de negocio.

Esta capa debe considerar algunas limitaciones propias del almacenamiento batch, como la alta latencia de lectura, la gestión de ficheros pequeños y las escrituras arbitrarias. Por ello, la solución deberá apoyarse en buenas prácticas de organización y consolidación de ficheros, utilizando formatos adecuados para mantener un rendimiento estable dentro del Lakehouse.

En síntesis, la capa de almacenamiento de FarmlA se construirá sobre un Lakehouse en Azure Data Lake Storage, donde el almacenamiento batch será repositorio principal y permanente, mientras que el almacenamiento streaming se utilizara como soporte temporal para datos que requieren acceso inmediato. De esta forma, la arquitectura podrá conservar el histórico, escalar con el crecimiento del volumen de datos y sostener tanto la analítica tradicional como los casos de uso en tiempo real.

2.4. CAPA PROCESAMIENTO

La capa de procesamiento, también conocida capa analítica, de transformación o de preparación, es responsable de aplicar transformaciones sobre los datos

almacenados y generar resultados útiles para el negocio. En FarmlA, esta capa debe soportar tanto procesamiento batch como streaming, ya que la empresa combina grandes volúmenes de datos históricos, con flujos de datos en tiempo real, como sensores agrícolas y demás. De este modo, la arquitectura puede responder tanto a necesidades de volumen como de velocidad dentro de una misma plataforma.

La solución propuesta utilizará Azure Databricks como eje principal para el debido procesamiento, ya que permite trabajar sobre el lakehouse y unificar cargas batch y streaming en un mismo entorno. En esta capa se ejecutarán procesos ETL de limpieza, validación, estandarización y otros métodos que busca transformar la información desde Bronze hasta Silver y posteriormente hacia Gold. Así, los datos de ventas podrán integrarse con inventarios, eventos de clientes y canales externos, mientras que la telemetría de sensores podrá relacionarse con variables operativas o zonas de cultivo. Esta estrategia permite construir una base analítica consistente y preparada para el consumo posterior.

Además, la capa de procesamiento podrá soportar distintos tipos de análisis según las necesidades FarmlA. Por un lado, el procesamiento batch permitirá trabajar con históricos, consolidaciones y análisis logísticos de mayor volumen. Por otro lado, el procesamiento streaming facilitará el tratamiento casi en tiempo real de eventos recientes, como clicks, compras o señales de sensores. A su vez, el uso de consultas SQL sobre el Lakehouse permitirá explotar los datos en un lenguaje ampliamente conocido en entornos empresariales, mientras que la misma base podrá servir en el futuro para casos de analítica avanzada y modelos predictivos.

2.5. CAPA DE SERVICIO

La capa de servicio tiene como finalidad disponibilizar los resultados del procesamiento para que puedan ser consumidos por usuarios finales o aplicaciones. Esta capa suele combinar varias tecnologías, ya que distintos patrones de consumo requieren distintos mecanismos de servicio y no existe una única tecnología capaz de cubrir todas las necesidades.

En FarmlA, los datos estructurados para reportar, seguimiento comercial y logística podrán servirse mediante *Azure SQL Database* y explotarse en Power BI, permitiendo construir dashboards e indicadores para ventas, inventario y distribución. Para datos de mayor volumen o con estructuras más flexibles, la arquitectura podrá apoyarse en *Azure Cosmos DB*, ya que los datastores NoSQL ofrecen escalabilidad horizontal y modelos de datos más flexibles para consumo por aplicaciones y APIs.

Cuando el consumo requiere acceso a información reciente, la capa de servicio podrá apoyarse en mecanismos orientados a streaming, mientras que el Lakehouse seguirá funcionando como repositorio principal. En este contexto, el Teorema CAP resulta relevante, ya que en sistemas distribuidos no es posible

maximizar simultáneamente consistencias, disponibilidad y tolerancia a participaciones; por ello, en ciertos servicios de FarmlA puede ser razonable priorizar disponibilidad y baja latencia sobre consistencia inmediata.

En síntesis, la capa de servicio de FarmlA combinará Power BI para consumo analítico, Azure SQL Database para datos estructurados y Azure Cosmos DB para consumo flexible por aplicaciones, permitiendo que la información procesada llegue al consumidor adecuado en el formato adecuado.

2.6. CAPA DE CONSUMO

La capa de consumo, también conocida como capa de explotación, tiene como objetivo hacer uso de los datos disponibles desde la capa de servicio. En FarmlA, los consumidores finales serán tanto personas como servicios: las personas accederán a la información mediante herramientas de BI o análisis, mientras que los servicios y aplicaciones consumirán los datos directamente desde la capa de servicio según sus necesidades operativas.

Para el consumo de negocio, la arquitectura se apoyará principalmente en Power BI, ya que permite construir informes y cuadros de mando para el seguimiento comercial, inventario y logística. A su vez, el consumo analítico podrá profundizar mediante notebooks y herramientas como Python o R, lo que permitirá profundizar en el análisis de ventas, comportamiento de clientes, sensores agrícolas y desempeño logístico. De este modo, FarmlA contará con un consumo BI orientado a la toma de decisiones y un consumo analítico orientado a exploración y análisis especializado.

3. Diagrama

